

Sistema inteligente para monitoreo e identificación temprana de melanoma

Sistemas Inteligentes
05 del mes de junio del 2023

Ariel N. Clemente Quispe*, Alexis P. Patzi Chavez[†], Sebastian Castro Rivas[‡], Andrés Ignacio Hinojosa Garnica[§]
Carrera de Ingeniería Mecatrónica y Carrera de Ingeniería en Sistemas
Universidad Católica Boliviana "San Pablo"
La Paz, Bolivia
*ariel.clemente, [†]alexis.patzi, [‡]sebastian.castro, [§] andres.hinojosa @ucb.edu.bo

Resumen—En el actual documento se presenta la elaboración y documentación de un sistema inteligente para el monitoreo e identificación temprana de melanoma, en el cual se realiza una extracción de un data set con un total de 17.805 imágenes, sin contar el método de "augmentation". Se presenta la justificación y el desarrollo debidamente explicado y documentado con la ayuda de gráficos y pruebas. De igual manera, se presentan las métricas finales utilizadas para el modelo y los resultados obtenidos, además de la documentación de pruebas.

Index Terms—Aprendizaje supervisado, CNN, identificación, melanoma

En resumen, este documento proporcionará una descripción detallada del desarrollo del modelo CNN para la detección temprana de melanoma y no melanoma en pacientes. Los resultados obtenidos demostrarán la eficacia y utilidad potencial de este modelo en la práctica clínica, brindando una herramienta adicional para los profesionales de la salud en la evaluación de lesiones cutáneas y contribuyendo a mejorar los resultados y la calidad de vida de los pacientes afectados por estas enfermedades.

I. INTRODUCCIÓN

El presente documento tiene como objetivo presentar el desarrollo, especificaciones y resultados de un modelo de Red Neuronal Convolucional (CNN, por sus siglas en inglés) para la detección temprana de melanoma y no melanoma en pacientes. El melanoma es un tipo de cáncer de piel altamente agresivo y potencialmente mortal, mientras que el cáncer de piel no melanoma abarca diferentes tipos de tumores cutáneos de menor gravedad. La detección temprana de estas enfermedades es fundamental para mejorar los resultados y la supervivencia de los pacientes.

En este documento, se detallará el proceso de desarrollo del modelo CNN, incluyendo la recopilación de datos dermatoscópicos, la preparación del conjunto de entrenamiento, la arquitectura del modelo y los parámetros de entrenamiento. Se presentarán las especificaciones técnicas del modelo, como el número de capas convolucionales, la función de activación utilizada y los algoritmos de optimización empleados.

Además, se mostrarán los resultados obtenidos a partir de la evaluación del modelo utilizando un conjunto de datos de prueba independiente. Estos resultados incluirán métricas de desempeño, como la precisión, la sensibilidad y la especificidad, que permitirán evaluar la eficacia del modelo en la detección de melanoma y no melanoma. Asimismo, se presentarán ejemplos visuales de las predicciones del modelo, destacando su capacidad para identificar patrones y características asociadas con estas enfermedades.

II. DESARROLLO

II-A. PROBLEMA A RESOLVER

El melanoma en Bolivia es una enfermedad de gran gravedad y preocupación debido a su agresividad y capacidad de propagación. Como mencioné anteriormente, el melanoma maligno es responsable de la gran mayoría de las muertes por cáncer de piel, lo que lo convierte en una enfermedad potencialmente mortal. Aunque no dispongo de datos estadísticos actualizados, se estima que cada año se diagnostican varios casos de melanoma en el país.

La progresión del melanoma puede ser rápida y puede manifestarse en forma de metástasis locales y a distancia. Estas metástasis pueden afectar no solo la piel, sino también otros órganos y huesos, lo que empeora significativamente el pronóstico de los pacientes. La supervivencia a largo plazo para aquellos con metástasis a distancia es baja, lo que destaca la importancia de la detección temprana y el tratamiento oportuno del melanoma.

Es fundamental concienciar a la población sobre la gravedad del melanoma y promover medidas preventivas, como el uso de protección solar adecuada, el autoexamen regular de lunares y la búsqueda de atención médica ante cualquier cambio sospechoso en la piel. Además, es esencial promover la educación sobre los factores de riesgo y la importancia

de una detección temprana, ya que un diagnóstico temprano aumenta las posibilidades de un tratamiento efectivo y una mejor prognosis

En conclusión, dadas las graves implicaciones del melanoma y el cáncer de piel en Bolivia, es crucial enfocarse en la detección temprana para mejorar los resultados y la supervivencia de los pacientes. En este sentido, la creación de un modelo de red neuronal convolucional (CNN, por sus siglas en inglés) para la detección temprana de melanoma y no melanoma en pacientes puede ser una herramienta prometedora. Un modelo CNN puede analizar imágenes dermatoscópicas y ayudar a identificar patrones y características específicas asociadas con el melanoma y otros tipos de cáncer de piel. Esto podría brindar un apoyo adicional a los dermatólogos en la evaluación de las lesiones cutáneas, permitiendo una detección más precisa y temprana de las malignidades cutáneas. La implementación de tecnologías de inteligencia artificial y aprendizaje automático en la atención médica dermatológica podría ayudar a mejorar la detección temprana, reducir la carga de trabajo de los profesionales de la salud y, en última instancia, mejorar los resultados para los pacientes afectados por el melanoma y otros tipos de cáncer de piel.

II-B. Metricas Finales

II-B1. PAMA:

- **Percepción:** El agente recibe información mediante una cámara; de una imagen del estado actual de la piel, esta cámara permite adquirir imágenes dermatoscópicas de la sección de piel a analizar.
- **Acción:** El agente aplica algoritmos y aprendizaje automático para analizar las imágenes de la piel y realizar una evaluación en la cual busca y decide si existen anomalías presentes.
- **Meta:** El agente tiene como meta detectar enfermedades de la piel o melanomas de forma precisa y temprana.
- **Ambiente:** El agente de inteligencia artificial opera en un entorno altamente relevante para el campo médico, específicamente en hospitales. Este ambiente es un lugar donde se brinda atención médica a los pacientes y se realizan diagnósticos y tratamientos relacionados con la salud de la piel.

II-B2. REAS:

- **Rendimiento:** El agente debe cumplir una alta precisión en la detección de melanomas o enfermedades en la piel de forma satisfactoria para el médico, operador o cliente.
- **Entorno:** El entorno de exposición del agente es en hospitales. Este entorno es un lugar donde se brinda atención médica a los pacientes y se realizan diagnósticos.
- **Actuadores:** El agente proporciona resultados mediante el envío de notificaciones al paciente y/o al médico encargado del diagnóstico. Los resultados presentan la detección o no de la imagen tomada del melanoma.

- **Sensores:** El agente adquiere las imágenes de la piel a analizar mediante una cámara de alta resolución.

II-B3. P->A:

- **Inicio -> Revisión inicial** Al iniciar el agente este tendrá un trabajo previo de revisión de los sensores y actuadores.
- **Análisis de detección -> Adquisición de imágenes ->** El agente seguidamente, adquiere las imágenes a analizar.
- **Preprocesamiento de imágenes -> Revisión de preprocesamiento** Antes de que las imágenes sean analizadas, las imágenes adquiridas entran a un preprocesamiento para mejorar la calidad y eliminar posibles ruidos o artefactos
- **Extracción de características -> Resultado de si se tiene o no melanoma** Con algoritmos de visión y aprendizaje automático para extraer características relevantes de las imágenes para que el agente genere resultados que incluyan un reporte del paciente y si se posee melanoma o no.

II-C. DIAGRAMA DE CLASES

Considerando el procedimiento a seguir se realiza el diagrama de clases, que se muestra en la figura 1. En este se puede visualizar principalmente al paciente, de quien se extraerá la información de nombre y edad, otros valores como el sexo del paciente no es de gran importancia para la detección, sin embargo, pueden ser consideradas. El paciente pasara por el reconocimiento de una cámara el cual nos lleva a la siguiente clase, el procesamiento de la imagen para regular su resolución y formato, esta imagen ingresa al sistema de aprendizaje supervisado, el cual previamente se encuentra entrenado con el dataset de preferencia donde se toma en cuenta, el tamaño de la lesión y el color, siendo las partes principales a detectar. Finalmente la imagen que pasa por el ML, tendrá que dar un diagnóstico dentro de las afecciones consideradas, para proporcionar al paciente con la información necesaria.

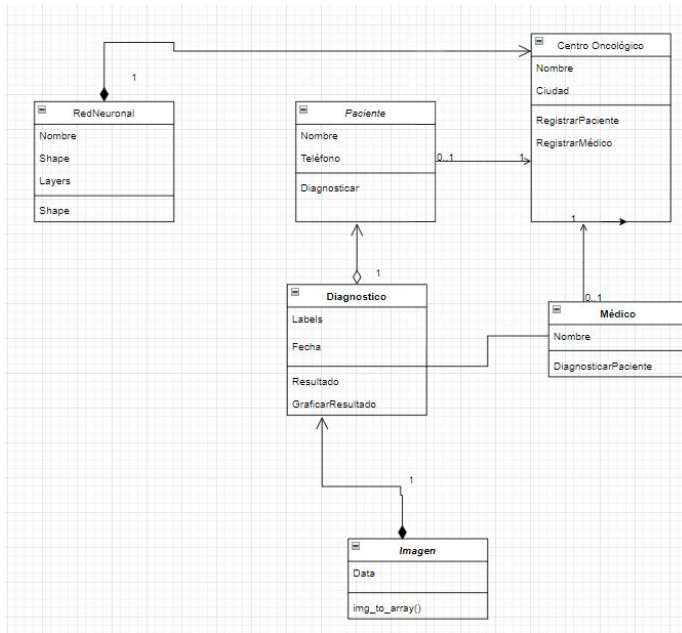


Figura 1. Diagrama de clases

II-D. DEFINICIÓN DE LAS VARIABLES

Tomando en cuenta el problema a resolver, las variables principales llegan a ser los tipos de afecciones a la piel, los cuales se especifican a continuación:

- Melanoma
- Melanocytic Nevus
- Carcinoma celular basal
- Queratosis actínica
- Queratosis benigno
- Dermatófibroma
- Lesión Vascular
- Carcinoma de células escamosas
- Ninguna

Siendo estas, la afecciones de la piel que se pueden reconocer, en su mayoría, con el aspecto visual de la piel. Sin embargo, dentro de los que es el queratosis benigno, existe diferentes tipos, los cuales no serán tomados en cuenta dado su parecido entre sí, estos sub-tipos de afecciones pueden ser correctamente diagnosticados extrayendo partes de piel y realizando un análisis celular. Por otro lado, se tomarán en cuenta los datos personales del paciente, siendo estas consideradas constantes. Las variables de la imagen obtenida, siendo la resolución, formato, principalmente considerando un preprocesamiento para su detección. Dentro de lo que serían las lesiones detectadas se consideran las variables de color, tamaño, que son las variables que el sistema podrá detectar. Finalmente, dentro de las diferentes afecciones previamente especificadas se considera sus nombres y características como variables importantes para el procesamiento de los datos.

II-D1. DATASETS DE ENTRENAMIENTO: Para el desarrollo del programa vamos a hacer uso de los siguientes datasets que ya tienen las etiquetas y están desarrollados por información de profesionales en el área de la salud. Para garantizar que las imágenes están caracterizadas y etiquetadas de manera correcta. Estos datasets consisten en la información necesaria para el entrenamiento y evaluación, de las cuales se encuentran datos, imágenes de diferentes tipos de melanoma obtenidos entre los años 2017 a 2019. Para el sistema de aprendizaje se hace uso de TensorFlow que es un sistema de aprendizaje automático de código abierto desarrollado por Google Brain Team en 2015. Es una biblioteca de software utilizada para el procesamiento de datos numéricos y de grandes dimensiones mediante grafos de flujo de datos.

II-E. FAMILIAS DE ALGORITMOS

El proceso de formación y modelado de aprendizaje automático para aplicar una red neuronal profunda (DNN) para detectar el melanoma cutáneo implica varios pasos clave. En primer lugar, se recopila un conjunto de datos de imágenes dermatoscópicas o datos clínicos, que consta de muestras de melanoma y no melanoma. Luego, los datos se procesan previamente, incluido el cambio de tamaño de las imágenes, la normalización de los valores de píxeles y la expansión del conjunto de datos para una mayor diversidad. A continuación, se diseña una arquitectura DNN adecuada, como una red neuronal convolucional (CNN), con capas convolucionales, de agrupación y totalmente conectadas. El modelo se entrena usando los datos de entrenamiento y sus pesos se ajustan usando algoritmos de optimización y propagación hacia atrás. Los hiperparámetros se ajustan con precisión para optimizar el rendimiento del modelo y se implementan técnicas como la regularización y el abandono para evitar el sobreajuste.

Un método alternativo de aprendizaje automático para resolver el problema de detección de melanomas en la piel es Support Vector Machines (SVM). SVM es un algoritmo de aprendizaje supervisado que se usa comúnmente para tareas de clasificación, incluida la clasificación de imágenes. Para aplicar SVM para la detección de melanoma, se recopila y preprocesa un conjunto de datos de imágenes dermatoscópicas o datos clínicos. A partir de las imágenes, se aplican características relevantes y técnicas de selección de características para reducir la dimensionalidad. Luego, el modelo SVM se entrena para encontrar el hiperplano que mejor separe las muestras de melanoma y no melanoma en el espacio de características. El ajuste de hiperparámetros se realiza para optimizar el rendimiento del modelo y el modelo SVM entrenado se evalúa mediante un conjunto de pruebas separado. El proceso de refinamiento iterativo incluye el ajuste de la extracción de características, la selección de características y los hiperparámetros en función de los resultados de la evaluación para mejorar el rendimiento del modelo SVM en la detección del melanoma cutáneo.

II-F. PROCEDIMIENTO Y MÉTRICAS DE EVALUACIÓN

II-G. Métricas de evaluación

La primera consiste en el análisis de las bases de datos, de tal modo que se pueda evidenciar que existe una cantidad igual de datos y que se tiene una suficiente cantidad para implementar el sistema de aprendizaje. La segunda consiste en analizar las gráfica de entrenamiento, al cual sería obtenida dependiendo de los datos obtenidos, comparando la precisión con la validación del entrenamiento de tal modo podemos evaluar el ajuste que tiene el aprendizaje. Y ver si es necesario realizar más ciclos o si existen errores como el overfitting, sesgo, underfitting, entre otros errores que podemos evidenciar.

```
fine_tune_epochs = 5
total_epochs = initial_epochs + fine_tune_epochs

history_fine = model.fit(train_dataset,
                        epochs=total_epochs,
                        initial_epoch=history.epoch(-1),
                        validation_data=validation_dataset)
```

Epoch 10/15
268/268 [=====] - 91s 227ms/step - loss: 0.2257 - accuracy: 0.9365 - val_loss: 0.2109 - val_accuracy: 0.9265
Epoch 11/15
268/268 [=====] - 58s 213ms/step - loss: 0.2223 - accuracy: 0.9397 - val_loss: 0.2074 - val_accuracy: 0.9275
Epoch 12/15
268/268 [=====] - 59s 218ms/step - loss: 0.2126 - accuracy: 0.9217 - val_loss: 0.2048 - val_accuracy: 0.9282
Epoch 13/15
268/268 [=====] - 66s 245ms/step - loss: 0.2090 - accuracy: 0.9251 - val_loss: 0.2033 - val_accuracy: 0.9286
Epoch 14/15
268/268 [=====] - 57s 211ms/step - loss: 0.2103 - accuracy: 0.9242 - val_loss: 0.2008 - val_accuracy: 0.9289
Epoch 15/15
268/268 [=====] - 58s 214ms/step - loss: 0.1992 - accuracy: 0.9269 - val_loss: 0.1992 - val_accuracy: 0.9286

Figura 2. Gráfica de evaluación del modelo, ejemplo

Por ultimo se tiene una cantidad de imágenes las cuales no ha visto el modelo denominada test, para la evaluación más precisa, en la que vamos a darle imágenes nuevas y evidenciar que tan bien está respondiendo el sistema. Dentro de lo que sería la evaluación durante el entrenamiento, es importante considerad los valores de error, como MAE verificando cual se adecua de mejor manera a nuestros datos y considerando el accuracy del entrenamiento.




Figura 3. Gráfica de evaluación del modelo, ejemplo

III. LIMITACIONES Y RECOMENDACIONES

A pesar de los avances en la tecnología de imágenes médicas, una de las principales limitaciones de este proyecto radica en la calidad de la cámara utilizada para capturar las imágenes dermatoscópicas, cámara con la que no se cuenta. La calidad de la cámara puede variar dependiendo del dispositivo utilizado, lo que puede afectar la claridad y los detalles de las imágenes. Una resolución baja o una mala iluminación pueden dificultar la detección precisa de características relevantes para la clasificación de lesiones cutáneas.

Otra limitación importante es la complejidad de trabajar con la cámara en el entorno de Colab (Google Colaboratory). Colab proporciona un entorno de programación en la nube, pero su compatibilidad y soporte para la interacción con cámaras externas pueden ser limitados. Esto puede dificultar la adquisición de imágenes en tiempo real o la integración fluida de la cámara en el flujo de trabajo del modelo CNN.

Como recomendación para futuras mejoras, se sugiere abordar tanto la calidad de la cámara como la interfaz de usuario. En cuanto a la calidad de la cámara, sería beneficioso contar con una cámara de alta resolución y una iluminación adecuada para obtener imágenes nítidas y detalladas. Además, se puede explorar la posibilidad de utilizar técnicas de mejora de imágenes para optimizar la calidad de las imágenes capturadas.

En relación a la interfaz, se recomienda desarrollar una interfaz de usuario intuitiva y fácil de usar, que permita a los

usuarios interactuar de manera eficiente con el modelo CNN y capturar imágenes de manera conveniente. Una interfaz bien diseñada facilitaría la adquisición de imágenes, el análisis de los resultados y la integración del modelo en la práctica clínica, lo que mejoraría la usabilidad y la experiencia del usuario.

IV. ANÁLISIS DE LOS RESULTADOS

Según lo previsto se tiene un modelo con una probabilidad de éxito de predicción del 98 %, donde también se cuenta con dos modelos uno con una amplia gama de capas y otro con una gama de capas mínima o la necesaria para la predicción.

V. ANEXOS

V-A. Contribución

Estudiante	Aporte
Sebastián Castro Rivas	32 %
Ariel Clemente Quispe	32 %
Alexis Pamela Patzi Chavez	32 %
Andres Ignacio Hinojosa Garnica	4 %